



目录

CONTENTS

01

.....

研究背景与问题

02

.....

核心工作与技术路线

03

.....

未来工作

04

.....

总结与展望

研究背景与问题

传统硬件设计方法的缺点

1. 高成本

- 依赖周期级仿真器（如 Timeloop、MAESTRO 等）评估每个候选设计。
- 一次完整搜索可能需数万次仿真，耗时数天甚至数周。

2. 低效率

- 一旦目标应用或设计约束（如面积、功耗）发生变化，整个流程需从零开始。
- 无法快速响应新任务（例如部署新 DNN 模型）。


3. 难复用

- 历史仿真数据被当作“一次性产物”，无法用于加速未来设计。
- 造成大量计算资源和专家经验的浪费。

现有离线方法的不足

PRIME: 损失函数将目标学习与约束学习耦合，可能导致优化冲突。

COMs: 其梯度法负采样在离散、高维、非平滑的硬件设计空间中效果不佳。



问题定义

$$\begin{aligned} \min_x & f(x) \\ \text{s.t. } & \begin{cases} \text{Area}(x) \leq \alpha_0 \\ \text{Feasible}(x) = 1 \end{cases} \end{aligned}$$


其中目标函数与约束条件无法用数学式显示表示。

PRIME 代理模型的整体框架

Embedding Layer: 将每个离散硬件参数（如 PE 数量、内存大小）映射为连续向量。

Transformer Encoder: 建模参数间的全局交互关系（如内存大小对延迟的影响取决于计算单元的数量）。

Mixture of Experts: 各自独立预测延迟，并通过门控网络分配专家权重。



核心工作与技术路线

改进一：解耦学习框架

PRIME 的损失函数（MSE 项 + 保守项 + 正则项）

$$L(\theta) = \mathbb{E}_{(x_i, y_i) \sim \mathcal{D}_f} [(f_\theta(x_i) - y_i)^2] - \alpha \mathbb{E}_{x_i^- \sim \text{opt}(f_\theta)} [f_\theta(x_i^-)] - \beta \mathbb{E}_{x_i' \sim \mathcal{D}_{inf}} [f_\theta(x_i')]$$

解耦后的损失函数（MSE 项 + 保守项）


$$L(\theta) = \mathbb{E}_{(x_i, y_i) \sim \mathcal{D}_f} [(f_\theta(x_i) - y_i)^2] - \alpha \left(\mathbb{E}_{x_i' \sim \text{opt}(f_\theta | C(x_i') \geq \tau)} [f_\theta(x_i^-)] - \mathbb{E}_{x_i \sim \mathcal{D}_f} [f_\theta(x_i)] \right)$$

结合 optimization with constraint learning (OCL) 方法，利用可行样本与不可行样本学习关于约束条件的黑盒，从而分离 PRIME 损失函数中的目标学习与约束学习，避免冲突。

优势

分工明确：代理模型可更专注地学习延迟预测任务，目标更聚焦。

灵活性高：约束模型无需固定模型类型，可针对性选用最适合表格数据的方案（如 LightGBM、神经网络等），能充分贴合表格数据的特征规律，提升适配性。



改进二：面向离散空间的保守训练

PRIME 原始负采样方法及其局限

梯度下降法：硬件参数是离散的，梯度无定义。使用 `one-hot + argmax` 更新，导致搜索过程不连续、负样本质量差。

萤火虫算法：在高维离散空间中易陷入局部循环，收敛行为不稳定（实验中观察到亮度周期性震荡）。

离散空间搜索的核心挑战

1. 离散性：参数取值为有限整数，无法使用基于梯度的局部搜索。
2. 非平滑性：目标函数对某些参数的微小变化极度敏感，形成“悬崖-高原”式复杂地形。
3. 高不可行率：可行设计仅占整个搜索空间的极小部分（狭窄流形），优化器极易陷入无效区域。

遗传算法的选择

1. 原生支持离散编码：直接操作整数下标，无需连续松弛。
2. 强大的全局探索能力：通过种群并行搜索，有效跨越非平滑地形，避免早熟收敛。
3. 高效处理约束：结合 Tessema & Yen 提出的自适应罚函数，在无需调参的前提下，可动态平衡“探索可行解”与“优化目标值”。

改进三：构建语义感知的嵌入空间

动机：负样本匹配失效

在保守训练中，需要为每个负样本（分布外点）匹配一个“语义相近”的训练样本（分布内点），以计算保守损失。



问题：实验发现，在原始嵌入空间中，可行点之间的语义距离分布稀疏且无序，导致匹配结果不可靠，影响了保守性训练的效果。

解决方案：引导模型学习任务相关的语义

通过对比学习预训练，引导模型学习一个任务导向的嵌入空间。让延迟值相近的可行设计在嵌入空间中彼此靠近，而延迟差异大的设计相互远离。

效果：嵌入空间质量显著提升

距离分布明显左偏，证明模型成功构建了一个“延迟相似则嵌入相近”的高质量语义空间，为后续的负样本匹配、排序和优化奠定了坚实基础。



引入进化多任务优化

不同 DNN 模型（如 MobileNetV2、U-Net 等）的硬件优化任务高度相似——它们共享相同的参数空间、约束条件和性能目标（最小化延迟）。

引入多任务优化的好处：

1. 效率提升：在一个统一的进化框架中并行优化多个任务，显著缩短总优化时间。
2. 质量提升：通过隐式知识迁移（如个体交叉、选择），一个任务在搜索中发现的“好设计”，可以启发其他任务跳出局部最优，从而提升最终解的质量。

扩展至多种数据流架构

PRIME 原始工作依赖于 Google 内部的 TPU 仿真器，其数据特征和评估逻辑不具通用性。

为了证明提出的方法是一个通用的硬件设计框架，而非仅适用于特定数据流的“特例”，应在开源、标准的评估工具（如 MAESTRO）上进行验证。

MAESTRO 支持的 NVDLA、ShiDianNao 等数据流，其硬件参数定义、性能瓶颈和可行域分布与 TPU 存在显著差异。这可能要求我们对代理模型的输入表示或训练策略进行针对性改进，以适应新的数据特性。

已完成工作

实现了解耦学习（OCL）框架。

用搭配自适应罚函数的 GA 成功解决了离散空间负采样问题。

通过对比学习构建了语义感知的嵌入空间，提升了模型排序能力。

代理模型在验证集上取得了稳定的 Kendall's Tau 指标（0.7~0.8）。

下一步计划

使用 MAESTRO 完成代理模型的硬件性能评估。

实现进化多任务优化模块，并与现有框架集成。

在 NVDLA、ShiDianNao 等不同数据流架构上进行全面实验验证。